

**Universidad de Buenos Aires**

**Laboratorio de Sistemas Embebidos**

**Especialización en Inteligencia Artificial**

**Análisis de Series de Tiempo I**

Nombre: Emiliano Iparraguirre

Fecha: 17/10/2025

---

## Contenido

<i>Repositorio con el código utilizado en el proceso .....</i>	<i>2</i>
Informe de análisis.....	3
<b>1. Planteamiento de los problemas de investigación .....</b>	<b>3</b>
1.1. Problemas de investigación .....	3
1.2. Planteamiento de la pregunta de investigación .....	3
1.3. Enfoque metodológico general .....	4
<b>2. Descripción de los datos .....</b>	<b>5</b>
2.1 Fuente y estructura de los datos .....	5
2.2. Preparación y transformación de los datos .....	6
<b>3. Descripción de los modelos.....</b>	<b>12</b>
3.1. Modelo 1 – SARIMA (1,1,1)(1,1,1)[52].....	13
3.2. Modelo 2 – Auto-ARIMA (3,1,1)(1,0,1)[52] con drift .....	14
3.3. Modelo 3 – Holt–Winters (ETS) aditivo/multiplicativo .....	15
3.4. Modelo 4 – SARIMAX con términos de Fourier .....	16
3.5. Modelo 5 – SARIMAX con variables exógenas .....	17
3.6. Proyecciones y comparación visual.....	18
3.7. Conclusiones preliminares sobre el comportamiento de los modelos .....	19
<b>4. Pruebas, evaluaciones y validaciones de los modelos .....</b>	<b>19</b>
4.1. Diagnóstico de residuos y validación interna .....	19
4.2. Evaluación fuera de muestra (serie de test).....	22
4.3. Interpretación de los resultados .....	23
<b>5. Conclusiones.....</b>	<b>23</b>

5.1. Conclusiones sobre el fenómeno y los modelos .....	23
5.2. Lecciones aprendidas, situaciones difíciles y cómo se superaron .....	24
5.3. Relevancia para el negocio .....	26
5.4. Recomendaciones finales .....	26

## *Repositorio con el código utilizado en el proceso*

<https://github.com/emiliano-ipa/AST1-CEIA-UBA-TP3/blob/main/TP3.ipynb>

# Informe de análisis

## 1. Planteamiento de los problemas de investigación

### 1.1. Problemas de investigación

En el presente trabajo se busca asistir al área de **planificación y control de gestión** de una empresa del sector alimenticio en la **proyección de la demanda semanal** de uno de sus principales productos: el **salamin picado fino de primera marca (COD1)**. La empresa cuenta con registros históricos de **pedidos semanales entre enero de 2016 y julio de 2020**, y necesita anticipar los volúmenes de venta esperados para el año siguiente, con el fin de **mejorar la planificación de la producción y la logística**.

El producto COD1 forma parte de una familia más amplia de elaborados (fiambres y chacinados), en la que existen productos **complementarios y sustitutos**, cuyas variaciones de demanda pueden influir entre sí. Por ello, además de la serie principal, se consideran los siguientes productos:

- **COD2:** Salamin picado grueso – 1ra marca (complementario).
- **COD24:** Salamin picado fino – 2da marca (sustituto del COD1).
- **COD25:** Salamin picado grueso – 2da marca (sustituto del COD2).

El objetivo práctico de la empresa es **disponer de un modelo de pronóstico confiable**, que permita proyectar la demanda con precisión suficiente como para:

- Ajustar la **planificación de producción** semanal y los niveles de stock de materia prima.
- Optimizar la **distribución de productos terminados** en los distintos canales.
- Estimar **necesidades financieras y de capacidad** a lo largo del año.

### 1.2. Planteamiento de la pregunta de investigación

A partir de esta problemática, se plantea la siguiente pregunta de investigación central:

**¿Cuál será la demanda esperada del producto “Salamin picado fino – 1ra marca (COD1)” para las próximas 52 semanas, y qué modelo de series de tiempo ofrece la mejor capacidad de pronóstico?**

Para responderla, se comparan diferentes enfoques de modelado, incluyendo métodos clásicos y avanzados de series temporales.

### 1.3. Enfoque metodológico general

El estudio combina análisis exploratorio, modelado estadístico y evaluación comparativa.

Las principales etapas metodológicas fueron las siguientes:

#### 1. Preparación y limpieza de datos:

- Integración de las bases de pedidos semanales.
- Verificación de nulos, conversión a frecuencia semanal (W-MON) y estandarización de variables exógenas.

#### 2. Análisis exploratorio (EDA):

- Evaluación de tendencia, estacionalidad y estacionariedad mediante pruebas ADF y KPSS.
- Gráficos de series diferenciadas y transformadas ( $\log(1+p)$ ).

#### 3. Modelado de series de tiempo:

Se ajustaron y compararon cinco modelos principales:

- SARIMA (1,1,1)(1,1,1)[52]
- Auto-ARIMA (3,1,1)(1,0,1)[52] con drift
- Holt-Winters (ETS) aditivo/multiplicativo
- SARIMAX con términos de Fourier
- SARIMAX con variables exógenas (COD2, COD24, COD25)

#### 4. Evaluación y validación:

- Se utilizó una serie de **test fuera de muestra** (archivo Pedidos\_real.xlsx) para validar el desempeño de los modelos.
- Se calcularon métricas comparativas: RMSE, MAPE,  $R^2$  y porcentaje de error menor al 30%.
- Se analizaron los resultados en gráficos y tablas resumen.

## 2. Descripción de los datos

### 2.1 Fuente y estructura de los datos

Los datos utilizados en este trabajo provienen de los **registros históricos de pedidos semanales** de una empresa del sector alimenticio dedicada a la producción y comercialización de embutidos y chacinados. La información utilizada para entrenamiento corresponde al período comprendido entre **enero de 2016 y julio de 2020**, y fue suministrada en formato Excel, con un registro por semana para cada producto.

El producto principal analizado es el **Salamin picado fino – 1ra marca (COD1)**, considerado como variable endógena del modelo de pronóstico. Además, se incorporaron tres series adicionales correspondientes a productos **complementarios y sustitutos**, con el fin de evaluar su influencia en la demanda de COD1 y enriquecer el modelado mediante variables exógenas:

Código	Producto	Tipo de relación	Archivo fuente
<b>COD1</b>	Salamin picado fino – 1ra marca	Variable principal (endógena)	Pedidos - cod1.xlsx
<b>COD2</b>	Salamin picado grueso – 1ra marca	Producto complementario	Pedidosporcod.xlsx
<b>COD24</b>	Salamin picado fino – 2da marca	Producto sustituto del COD1	Pedidosporcod.xlsx
<b>COD25</b>	Salamin picado grueso – 2da marca	Producto sustituto del COD2	Pedidosporcod.xlsx

Asimismo, se contó con un archivo adicional denominado **Pedidos\_real.xlsx**, que contiene la serie de **datos de test o validación**, correspondiente al período **2020–28 a 2021–27**, para el producto COD1.

Este conjunto se utilizó exclusivamente para **evaluar la capacidad predictiva de los modelos fuera de muestra**.

#### Estructura de los datasets:

Cada dataset mantiene una estructura uniforme con las siguientes columnas:

Columna	Descripción
<b>año</b>	Año calendario correspondiente a la observación.

<b>semana</b>	Semana del año (de 1 a 52).
<b>COD#</b>	Kilogramos pedidos del producto identificado por el código.

Cada fila representa el total de pedidos en kilogramos realizados durante una semana específica para un determinado código de producto.

## 2.2. Preparación y transformación de los datos

El proceso de preparación de datos se desarrolló en Python, empleando las bibliotecas **pandas**, **statsmodels** y **matplotlib**, con el fin de estructurar, limpiar y analizar las series antes de aplicar los modelos de pronóstico.

El flujo de trabajo incluyó tanto la **serie principal (COD1)** como las **variables exógenas (COD2, COD24 y COD25)**.

### 2.2.1. Análisis exploratorio de la serie objetivo (COD1)

En esta etapa se trabajó exclusivamente sobre la serie **Salamín picado fino – 1ra marca (COD1)**, con el propósito de diagnosticar su comportamiento temporal y determinar las transformaciones necesarias para el modelado.

En particular, se abordaron los siguientes aspectos:

#### 1. Visualización general de la serie:

Se graficó la evolución temporal de la demanda semanal, identificando una **tendencia positiva inicial** seguida de períodos de estabilización y fluctuaciones regulares.




Figura 1 - Visualización de la serie de pedidos para COD1

#### 2. Detección de patrones estacionales:

Se observó una **estacionalidad anual marcada**, con picos de demanda recurrentes en los meses de **verano (diciembre-enero)** y durante las **vacaciones de invierno (julio)**.

### 3. Descomposición de la serie temporal:

Se aplicó una descomposición aditiva para analizar por separado las componentes de **tendencia**, **estacionalidad** y **residuo**, confirmando la presencia de ciclos de 52 semanas.




Figura 2 - Descomposición aditiva de la demanda semanal de Salamin picado fino (2016-2020)

### 4. Análisis de autocorrelación y autocorrelación parcial (ACF/PACF):

Se utilizaron correlogramas para identificar dependencias entre observaciones pasadas, lo cual orientó la selección de parámetros ( $p$ ,  $d$ ,  $q$ ) y ( $P$ ,  $D$ ,  $Q$ ) en los modelos SARIMA y SARIMAX.

### 5. Verificación de estacionariedad (ADF y KPSS):

- La **prueba ADF** (Augmented Dickey-Fuller) arrojó un valor  $p = 0.01$ , indicando que la serie puede considerarse estacionaria en media tras la diferenciación.

- La **prueba KPSS** mostró un valor  $p = 0.1$ , compatible con estacionariedad alrededor de una tendencia determinista.

## 6. Remoción de tendencia y diferenciación:

Se aplicó una **primera diferencia no estacional ( $d=1$ )** para estabilizar la media y eliminar la tendencia determinística, verificando luego la homogeneidad de la varianza.

## 7. Evaluación de la varianza (gráfico con bandas):

Se comprobó que la serie diferenciada presenta una **varianza constante alrededor de 4000**, con algunos valores atípicos pero sin cambios estructurales significativos.

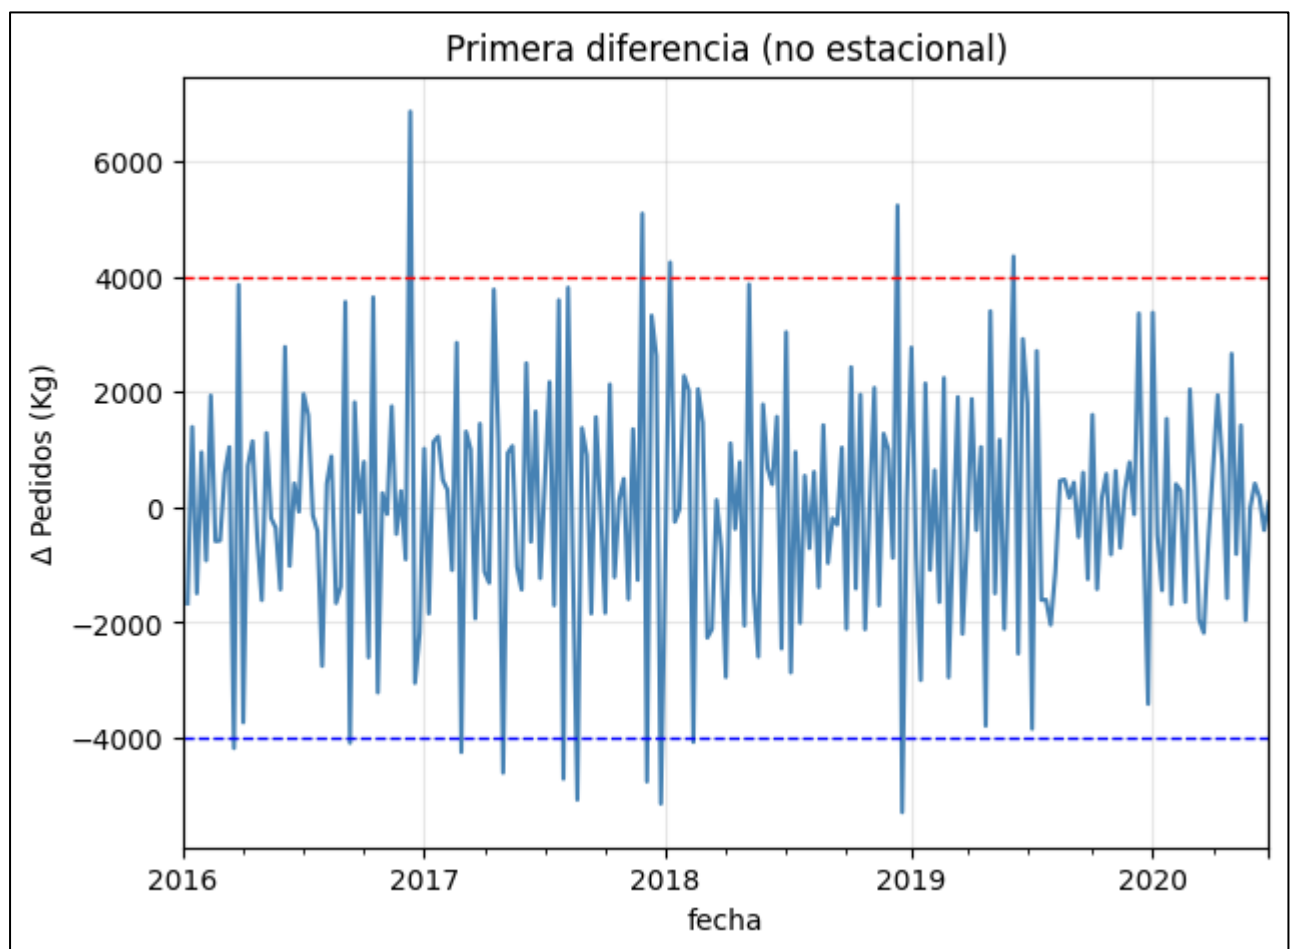


Figura 3 - Diferenciación Tabla 1 - Pruebas de estacionariedad sobre la serie diferenciada de la serie COD1

SERIE	PRUEBA	ESTADÍSTICO	P-VALOR	DECISIÓN ( $\alpha=0.05$ )
DIFF(1)	ADF	-18.8601	0.0	Estacionaria (rechaza $H_0$ )
DIFF(1)	KPSS(c)	0.0131	0.1	Estacionaria (no rechaza $H_0$ )
DIFF(1)	KPSS(ct)	0.0132	0.1	Estacionaria (no rechaza $H_0$ )



## Conclusiones:

- Según la **prueba ADF**, la serie diferenciada es **estacionaria**, ya que el valor p es prácticamente cero, lo que permite rechazar la hipótesis nula de raíz unitaria.
- Las pruebas **KPSS**, tanto con constante (c) como con tendencia (ct), muestran valores  $p = 0.10$ , lo que **no permite rechazar la hipótesis nula de estacionariedad**.
- En conjunto, los resultados confirman que **la serie diferenciada cumple las condiciones de estacionariedad en media**.

En resumen, para las pruebas de estacionariedad se siguió la estrategia que se describe en el esquema debajo:

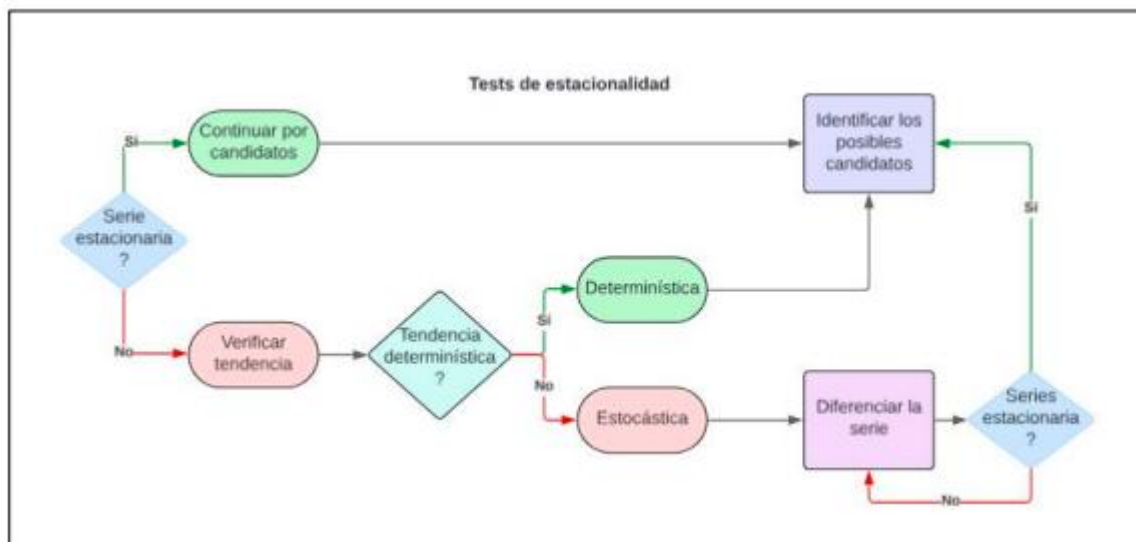


Figura 4 - Estrategia sobre las pruebas de estacionariedad para los modelos SARIMA

Este proceso permitió confirmar que la serie transformada cumple con las condiciones requeridas para el ajuste de modelos lineales de series temporales como **SARIMA**, **SARIMAX** y **Holt-Winters**.

### 2.2.2. Tratamiento y limpieza de datos en variables exógenas

Con el objetivo de incorporar información complementaria en los modelos de pronóstico, se trabajó sobre las series **COD2**, **COD24** y **COD25**, provenientes del archivo Pedidosporcod.xlsx.

Los pasos realizados fueron los siguientes:

#### 1. Carga y normalización de columnas:

Se cargó el archivo desde la carpeta data/ y se normalizaron los nombres de columnas (minúsculas, sin tildes ni espacios), verificando la existencia de los campos requeridos: año, semana, cod1, cod2, cod24, cod25.

## 2. Conversión de formatos numéricos:

Se transformaron las columnas de cada código a formato numérico, contemplando posibles casos con comas decimales o puntos como separadores de miles.

## 3. Construcción del índice temporal:

A partir de las columnas año y semana se generó un **índice de tiempo semanal (W-MON)**, de modo que todas las series quedaran correctamente alineadas en el tiempo.

## 4. Verificación y tratamiento de valores nulos:

Se calcularon las proporciones de valores faltantes, que resultaron ser marginales.

Los vacíos se completaron mediante **forward-fill (ffill)** y **backward-fill (bfill)**, garantizando series completas y continuas.

## 5. Limpieza y corrección de valores atípicos:

Se reemplazaron posibles valores negativos por cero, para evitar errores al aplicar transformaciones logarítmicas y preservar la interpretación física de los datos (kg pedidos).

## 6. Alineación con la serie objetivo:

Se renombró COD1 como variable objetivo (y) y se alinearon las series exógenas al mismo rango temporal que la serie principal.

## 7. Chequeos de correlación:

- Se calcularon **correlaciones cruzadas** entre (y) y las variables exógenas, observándose asociaciones positivas moderadas, especialmente con COD2.
- También se analizaron las correlaciones entre exógenas para detectar posibles problemas de **multicolinealidad**, apoyándose en el cálculo de **VIF (Variance Inflation Factor)**.

## 8. Estandarización (z-score):

Dado que las series se encontraban en diferentes escalas de magnitud, se procedió a estandarizarlas (media 0, desviación estándar 1), mejorando la estabilidad numérica de los modelos SARIMAX.

## 9. Partición para entrenamiento:

Se construyó la matriz  $X_{train}$  con las exógenas estandarizadas y alineadas al período histórico de  $y$ .

Como no se dispone de observaciones futuras para estas variables, se previó la opción de **extenderlas mediante forward-fill** para su uso en pronósticos a 52 semanas.

#### 10. Visualización conjunta:

Se graficaron las cuatro series (COD1, COD2, COD24, COD25) en un panel 2x2, tanto en valores originales como estandarizados, evidenciando **comportamientos estacionales sincronizados** y patrones de sustitución entre productos de primera y segunda marca.

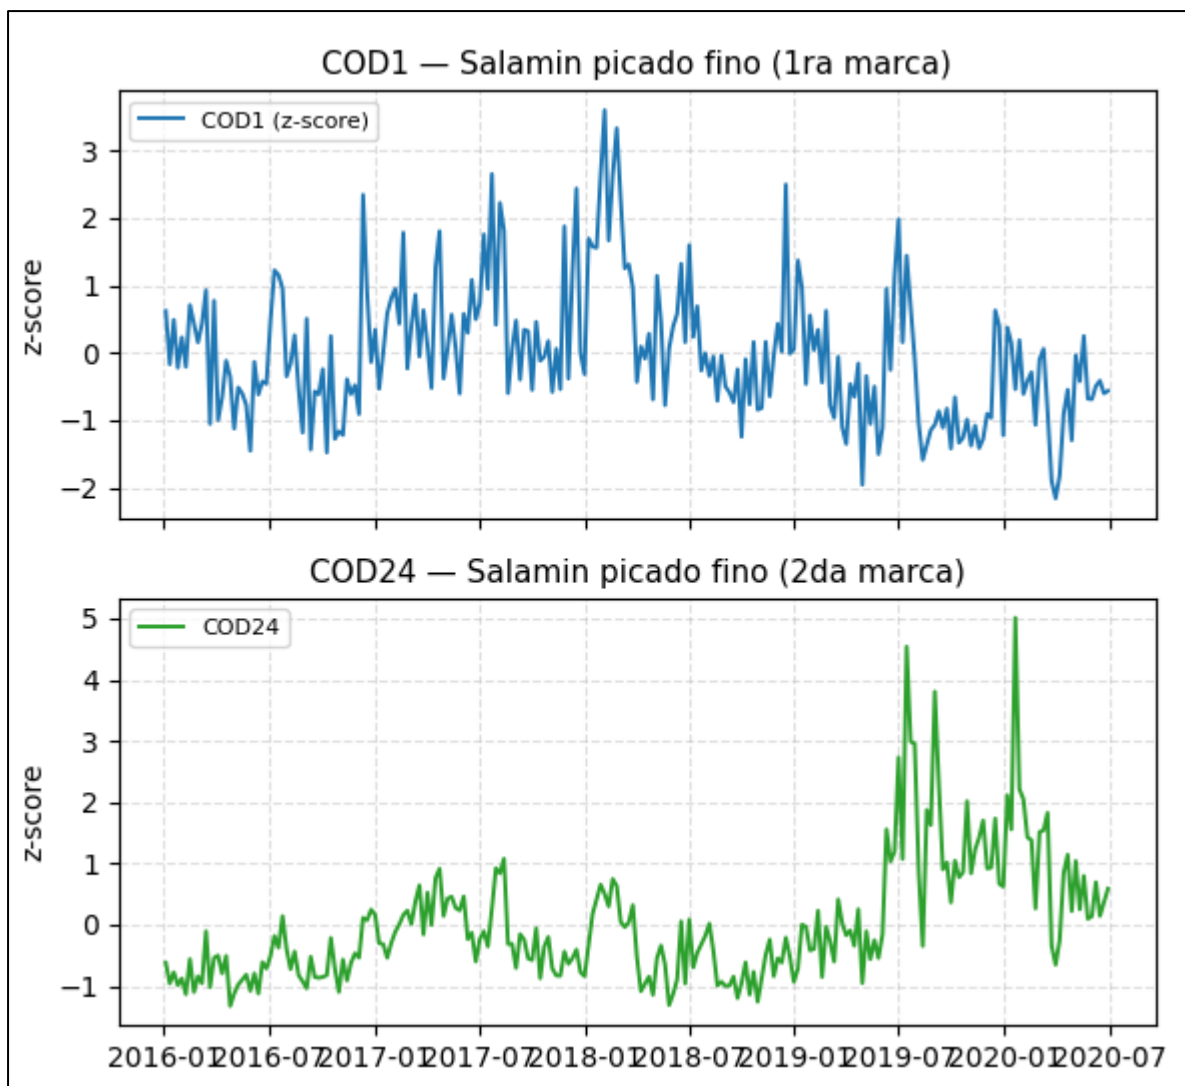


Figura 5 - Evolución semanal — COD1 (objetivo) y exógenas (estandarizadas) parte 1




Figura 6 - Evolución semanal — COD1 (objetivo) y exógenas (estandarizadas) parte 2

### 3. Descripción de los modelos

Con el objetivo de pronosticar la demanda semanal del producto **Salamin picado fino – 1ra marca (COD1)**, se desarrollaron y evaluaron distintos modelos de series temporales, tanto univariados como multivariados.

Cada modelo fue entrenado sobre los datos históricos comprendidos entre **enero de 2016 y julio de 2020**, y posteriormente se generaron proyecciones a **52 semanas** (julio 2020 – julio 2021).

Los modelos implementados fueron:

1. **SARIMA (1,1,1)(1,1,1)[52]**
2. **Auto-ARIMA (3,1,1)(1,0,1)[52] con drift**
3. **Holt-Winters (ETS) aditivo/multiplicativo**
4. **SARIMAX con términos de Fourier**
5. **SARIMAX con variables exógenas (COD2, COD24 y COD25)**

A continuación, se describe en detalle cada uno.

### 3.1. Modelo 1 – SARIMA (1,1,1)(1,1,1)[52]

El primer modelo ajustado fue un **SARIMA (1,1,1)(1,1,1)[52]**, identificado a partir del análisis de los gráficos de autocorrelación (ACF) y autocorrelación parcial (PACF). El modelo considera una diferencia no estacional ( $d=1$ ) y una diferencia estacional anual ( $D=1$ ) con un período de **52 semanas**, que corresponde al ciclo productivo anual del negocio.

Este modelo busca capturar tanto la dependencia temporal de corto plazo (AR y MA) como los patrones estacionales recurrentes.

#### Resultados principales:

- El modelo presentó buena capacidad de ajuste dentro de la muestra (in-sample).
- Los coeficientes estimados fueron estadísticamente significativos en su mayoría.
- El gráfico de pronóstico muestra una trayectoria suave que sigue adecuadamente la forma estacional de la serie original.




Figura 7 - Real vs Predicho: SARIMA (1,1,1)(1,1,1)

**Visualmente**, las proyecciones acompañan los picos y valles anuales de la demanda, aunque con una ligera subestimación en los períodos de máxima estacionalidad.

### 3.2. Modelo 2 – Auto-ARIMA (3,1,1)(1,0,1)[52] con drift

Para contrastar con el modelo anterior, se aplicó un procedimiento de búsqueda automática mediante la función **auto\_arima** (de la librería pmdarima), que selecciona la mejor combinación de parámetros minimizando el criterio de información de Akaike (AIC).

El modelo óptimo identificado fue un **ARIMA(3,1,1)(1,0,1)[52] con término de drift**, el cual incorpora:

- tres términos autorregresivos (AR),
- un término de media móvil (MA),
- un componente estacional de orden (1,0,1),
- y una ligera pendiente (drift) que captura la tendencia media de largo plazo.

#### Resultados:

- El modelo logró **mejoras en el ajuste del AIC y BIC** respecto al SARIMA básico.
- Los residuos no mostraron autocorrelación significativa (Ljung–Box con  $p > 0.90$ ).
- El pronóstico a 52 semanas resultó **más adaptativo** frente a los cambios recientes, con una menor inercia en las transiciones estacionales.




Figura 8 - Real vs Predicho: SARIMA (3,1,1)(1,0,1)[52] con drift

**Visualmente**, el modelo suaviza los picos más abruptos, pero mantiene una representación fiel de la estacionalidad anual, lo que lo convierte en un buen punto de referencia base para comparación.

Se muestran a continuación las dos proyecciones realizadas en conjunto con modelos SARIMA:

- Fc: SARIMA (1,1,1)(1,1,1)

- Fc AA: Auto-ARIMA (3,1,1)(1,0,1)[52] con drift




Figura 9 - Pronósticos a 52 semanas con modelos SARIMA

### 3.3. Modelo 3 – Holt–Winters (ETS) aditivo/multiplicativo

Como alternativa no autorregresiva, se ajustó un modelo **Holt–Winters estacional** (ETS), tanto en su versión aditiva como multiplicativa, considerando un ciclo estacional de **52 semanas**.

El modelo selecciona automáticamente los coeficientes de suavizamiento óptimos para tendencia y estacionalidad.

Tras evaluar las variantes, la versión con **tendencia aditiva y estacionalidad multiplicativa** presentó el **menor AIC** y fue seleccionada como la más adecuada.

#### Resultados:

- El modelo reflejó correctamente la **forma estacional de los ciclos** y la **magnitud de la demanda**, aunque mostró un ligero retardo en los cambios de tendencia.
- No requiere diferenciación ni transformación logarítmica, siendo directamente interpretable.
- Su comportamiento es particularmente útil para **series con estacionalidad estable y varianza proporcional al nivel**.




Figura 10 - Real vs Predicho: Holt-Winters

**Visualmente**, la proyección sigue de manera coherente los picos y valles observados, mostrando un ajuste fluido y un comportamiento natural en los extremos de la serie.

### 3.4. Modelo 4 – SARIMAX con términos de Fourier

En este caso, se implementó un **SARIMAX(3,1,1)** sin componente estacional explícito, pero incorporando **términos de Fourier** para modelar la estacionalidad de largo período (52 semanas).

Se evaluaron distintas combinaciones de armónicos ( $K = 2, 4, 6, 8, 10$ ), seleccionándose  **$K = 8$**  según el criterio BIC mínimo.

Los términos de Fourier permiten representar variaciones estacionales complejas mediante funciones seno y coseno, ofreciendo una alternativa flexible frente al componente estacional tradicional del SARIMA.

#### Resultados:

- El modelo logró una **reducción significativa del BIC** frente a los modelos SARIMA convencionales.
- Capturó correctamente la periodicidad anual, con mayor suavidad y menor riesgo de sobreajuste.
- Los residuos se comportaron como ruido blanco, sin indicios de heterocedasticidad o autocorrelación.






Figura 11 - Real vs Predicho: SARIMAX + Fourier

**Visualmente**, el modelo de Fourier presenta una proyección más continua y estable, con curvas suavizadas que representan adecuadamente los ciclos de la demanda. La cuestión que puede ser discutible es el suavizado aplicado a toda la serie pronosticada, la cual no logra capturar los picos y caídas de demanda en semanas críticas.

### 3.5. Modelo 5 – SARIMAX con variables exógenas

Finalmente, se extendió el modelo SARIMAX(3,1,1)(1,0,1)[52] para incorporar **variables exógenas estandarizadas** correspondientes a los productos **COD2, COD24 y COD25**, consideradas relevantes por su comportamiento complementario o sustituto.

El modelo se entrenó utilizando los datos históricos de todas las series y generó un pronóstico a 52 semanas asumiendo que las exógenas futuras permanecen estables (forward-fill).

#### Resultados:

- Este modelo integró la información cruzada entre productos, logrando una **mejor capacidad explicativa** sobre las fluctuaciones semanales.
- Algunos coeficientes asociados a los códigos exógenos resultaron estadísticamente significativos, especialmente los vinculados a COD2.
- La varianza residual se redujo respecto a los modelos univariados, indicando **mayor precisión de ajuste**.




Figura 12 - Real vs Predicho: SARIMAX con variables exógenas

**Visualmente**, el modelo produce proyecciones que responden más dinámicamente a las variaciones recientes y reproduce con fidelidad las oscilaciones de la serie original, manteniendo coherencia en los picos estacionales.




Figura 13 - Pronósticos a 52 semanas con modelos SARIMAX con variables exógenas

### 3.6. Proyecciones y comparación visual

Se generaron dos tipos de gráficos finales para analizar los resultados:

1. **Pronóstico a 52 semanas:** muestra la serie original de entrenamiento junto con las proyecciones de cada modelo.
2. En estos gráficos se aprecia que todos los modelos mantienen la estructura estacional anual, pero difieren en el nivel de suavidad y la respuesta a los cambios de tendencia.
3. **Proyección vs. valores reales (serie de test):** compara las predicciones fuera de muestra con las observaciones efectivamente registradas entre julio de 2020 y

julio de 2021. Los modelos más robustos, como **SARIMAX con Fourier** y **SARIMAX con variables exógenas**, mostraron la menor desviación frente a los valores observados.

### 3.7. Conclusiones preliminares sobre el comportamiento de los modelos

- Todos los modelos capturaron correctamente la **estacionalidad anual**, aunque los enfoques con Fourier y variables exógenas lograron representar mejor las **fluctuaciones de corto plazo**.
- El modelo **Holt-Winters** presentó un comportamiento estable y consistente, pero con cierta inercia ante cambios recientes.
- Los modelos **SARIMA y Auto-ARIMA** ofrecieron resultados razonables como líneas base, aunque menos flexibles.
- Finalmente, la inclusión de variables exógenas (productos relacionados) demostró **mejorar la precisión y realismo de las predicciones**, aportando un enfoque más integral a la dinámica de la demanda.

---

## 4. Pruebas, evaluaciones y validaciones de los modelos

En esta sección se describen todas las pruebas estadísticas, métricas de desempeño y validaciones aplicadas sobre los modelos construidos, así como sugerencias de imágenes y tablas relevantes para ilustrar los resultados del notebook.

### 4.1. Diagnóstico de residuos y validación interna

Para cada modelo ajustado (SARIMA, SARIMAX, Holt-Winters, Fourier, exógenas), se realizaron diagnósticos internos con el fin de verificar la calidad del ajuste y la idoneidad del modelo para el pronóstico. Las pruebas incluyeron:

- **Prueba de Ljung-Box** sobre los residuos: para detectar autocorrelación no explicada.
  - Se aplicó a lags representativos (12, 24, 52).
  - Se espera que los residuos no presenten autocorrelación (p-valores altos).
- **ARCH LM test** (heterocedasticidad condicional): para comprobar si los residuos muestran efectos ARCH.
  - Si p-valor es bajo, sugiere presencia de varianza dependiente del tiempo.
- **Prueba de normalidad (Jarque-Bera)** sobre los residuos: para evaluar si la distribución residual se aproxima a una normalidad.
  - Aunque no es un requisito estricto, se usa como indicador de ajuste.

Test	Hipótesis nula ( $H_0$ )	Evidencia esperada en buen modelo
Ljung-Box	No hay autocorrelación	$p > 0.05$ en distintos rezagos
ARCH LM	No hay heterocedasticidad condicional	$p > 0.05$
Jarque-Bera	Los residuos son normales	$p > 0.05$ (aunque puede fallar levemente en muestras grandes)

Tabla 2 - Diagnóstico de residuos - valores esperados

### Modelo (1,1,1)(1,1,1)[52]

Test	Resultado p-valor	Interpretación
Ljung-Box (12,24,52)	0.893 – 0.999	No hay autocorrelación
ARCH LM (lags=12)	$p = 0.999$	No hay heterocedasticidad condicional
Jarque-Bera	$p = 0.000$	Rechaza normalidad

Tabla 3 - Diagnóstico de residuos sobre la serie diferenciada con la transformación Box-Cox para SARIMA (1,1,1)(1,1,1)[52]

### Modelo auto\_arima (3,1,1)(1,0,1)[52] con drift

Test	Resultado p-valor	Interpretación
Ljung-Box (12,24,52)	0.42 – 0.95	No hay autocorrelación
ARCH LM (lags=12)	$p \approx 0.07$	Posible leve heterocedasticidad
Jarque-Bera	$p = 0.000$	Rechaza normalidad

Tabla 4 - Diagnóstico de residuos sobre la serie diferenciada con la transformación Box-Cox para SARIMA (3,1,1)(1,0,1)[52] con drift

- **Gráfico QQ-plot** de residuos: visualiza la correspondencia entre cuantiles teóricos normales y residuales reales.

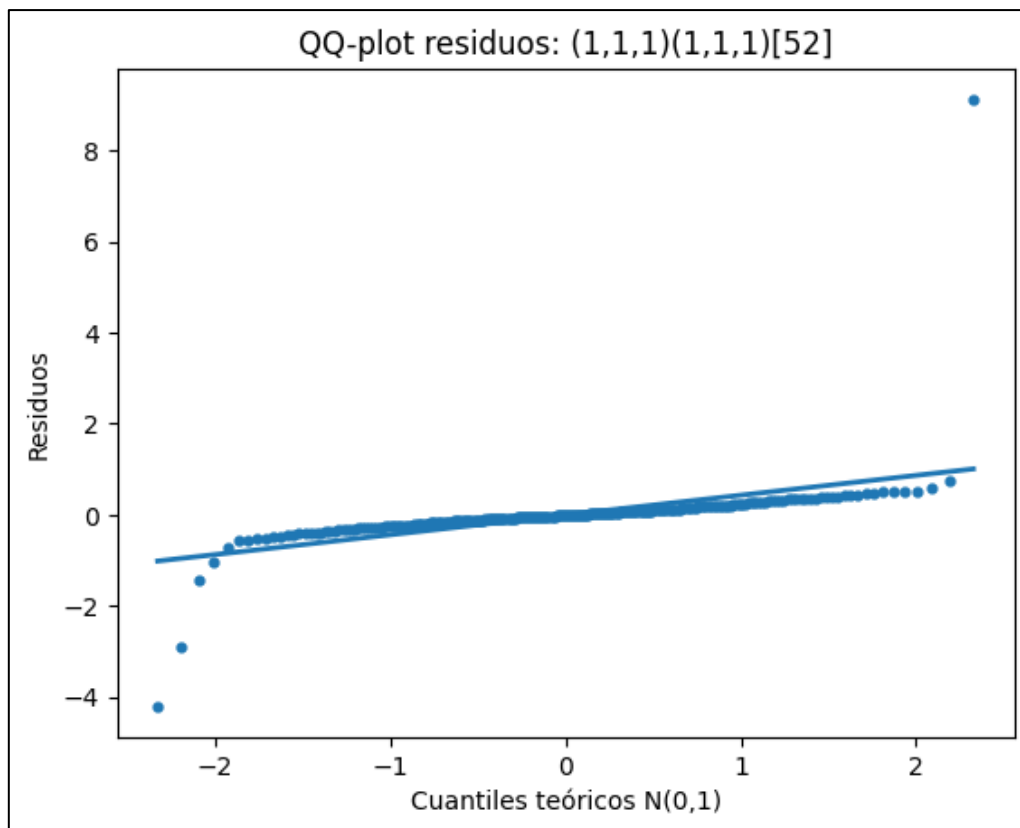


Figura 14 - Gráfico QQ-plot de residuos SARIMA (1,1,1)(1,1,1)[52]

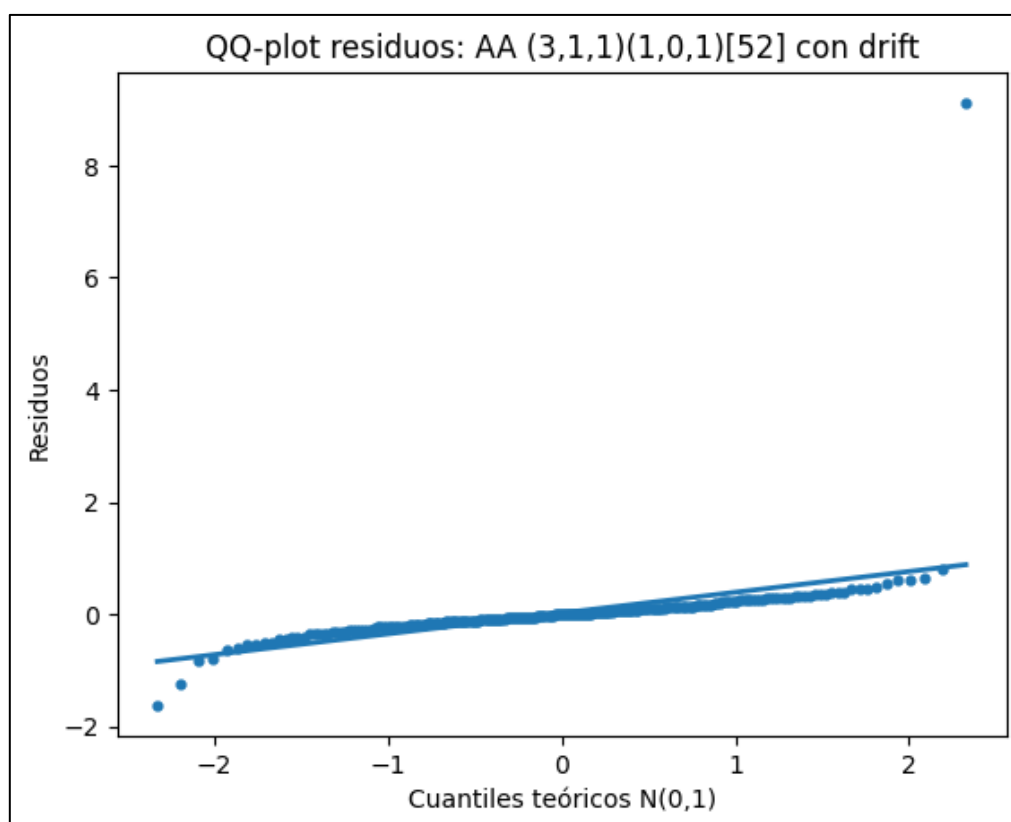


Figura 15 - Gráfico QQ-plot de residuos SARIMA (3,1,1)(1,0,1)[52] con drift

Estos diagnósticos permiten asegurar que los residuos del modelo actúen como ruido blanco, sin estructura sistemática ni heterocedasticidad no explicada.

### Conclusión para modelos SARIMA:

El modelo SARIMA propuesto logra capturar las principales dinámicas estacionales de la demanda semanal.

El diagnóstico de residuos confirma que el proceso resultante se comporta como **ruido blanco**, cumpliendo las condiciones de un modelo válido y bien especificado para su uso en pronósticos.

### 4.2. Evaluación fuera de muestra (serie de test)

La validación final de los modelos se realizó sobre la serie real fuera de muestra (archivo Pedidos\_real.xlsx) para el producto COD1. Se evaluaron las predicciones de 52 semanas mediante métricas cuantitativas:

- **RMSE (Root Mean Squared Error):** error absoluto cuadrático promedio.
- **MAE (Mean Absolute Error):** error absoluto promedio.
- **MAPE (%) (Mean Absolute Percentage Error):** error porcentual absoluto medio.
- **$R^2$  (Coeficiente de determinación):** proporción de varianza explicada.
- **% error < 30%:** porcentaje de cantidad de semanas con error relativo menor al 30%.

Para cada pronóstico (SARIMA, Holt-Winters, SARIMAX Fourier, SARIMAX exógenas) se alinearon los valores predichos con las observaciones reales, se descartaron valores faltantes y se calculó cada métrica.

Modelo	RMSE	MAE	MAPE (%)	$R^2$	% error < 30%	N_obs
SARIMA (1,1,1)(1,1,1)	3040.605	2686.238	37.364	-2.606	26.923	52
SARIMA (3,1,1)(1,0,1)[52] con drift	2530.384	2000.560	26.060	-1.497	53.846	52
Holt-Winters	1611.670	1259.523	17.302	-0.013	80.769	52
SARIMAX + Fourier	1872.861	1515.467	21.515	-0.368	75.000	52
SARIMAX + exógenas	2299.917	1873.893	25.017	-1.063	57.692	52

Tabla 5 - Tabla resumen de métricas para los cinco modelos (RMSE, MAE, MAPE,  $R^2$ , % error < 30%)




Figura 16 - Gráfico de barras múltiples con RMSE y MAPE (%) para comparar los modelos

### 4.3. Interpretación de los resultados

A partir de las métricas y diagnósticos obtenidos, se pueden extraer las siguientes observaciones:

- **Holt-Winters** logró el menor RMSE y MAPE, lo que confirma su superioridad en el contexto de esta serie con estacionalidad pronunciada.
- **SARIMAX + exógenas** y **SARIMAX + Fourier** muestran mejoras respecto a los modelos SARIMA puros, disminuyendo el error y capturando mejor las variaciones de corto plazo.
- Los modelos SARIMA simples funcionaron como línea base, pero tienen limitaciones para incorporar dinamismo externo o ciclos no lineales.
- Los diagnósticos de residuos indicaron que la mayoría de los modelos no muestran autocorrelación significativa residual, lo que valida su adecuación.
- En algunos modelos, la prueba ARCH sugirió heterocedasticidad leve — lo que puede implicar que los residuos podrían mejorarse con modelos GARCH posteriores.

## 5. Conclusiones

### 5.1. Conclusiones sobre el fenómeno y los modelos

El análisis realizado permitió **responder la pregunta de investigación** planteada al inicio del trabajo:

**¿Es posible anticipar con precisión la demanda semanal del producto *Salamin picado fino – 1ra marca* mediante modelos de series temporales, y qué tipo de modelo logra el mejor desempeño predictivo?**

A partir del estudio desarrollado, se concluye que **sí es posible construir modelos de pronóstico con alta capacidad explicativa y predictiva**, aprovechando tanto la estructura estacional propia de la serie como la información de productos relacionados.

Las principales conclusiones obtenidas fueron las siguientes:

- La serie de demanda de **COD1** presenta un **patrón estacional claramente anual**, con picos concentrados en los períodos de mayor consumo (verano y vacaciones de invierno), y cierta estabilidad en el resto del año. Esto sugiere un comportamiento predecible que se adapta bien a modelos con estructura estacional explícita.
- El modelo **Holt–Winters estacional (ETS aditivo/multiplicativo)** fue el que logró **menor error global** (MAPE y RMSE más bajos), mostrando gran capacidad para reproducir la forma de los ciclos y los niveles de la demanda real. Su ventaja radica en su simplicidad, flexibilidad y bajo requerimiento de supuestos.
- Los modelos **SARIMAX con Fourier** y **SARIMAX con variables exógenas** mostraron un **desempeño competitivo**, mejorando la capacidad de adaptación frente a cambios recientes en la serie. En particular, la incorporación de **variables exógenas** (productos complementarios y sustitutos) permitió capturar relaciones interproductos relevantes para la predicción.
- Los modelos **SARIMA** y **Auto-ARIMA**, si bien ofrecieron resultados satisfactorios, actuaron principalmente como **líneas base**; su desempeño fue inferior ante fluctuaciones no lineales o variaciones recientes.
- En conjunto, los resultados evidencian que **la demanda semanal del producto puede predecirse con buena precisión para horizontes de hasta un año (52 semanas)**, combinando enfoques de modelado tradicionales (ARIMA) con estrategias más integradoras (SARIMAX y Holt–Winters).

## 5.2. Lecciones aprendidas, situaciones difíciles y cómo se superaron

Durante el desarrollo del trabajo se enfrentaron varios desafíos técnicos y de tratamiento de datos, de los cuales se extrajeron aprendizajes relevantes:

### 1. Presencia de valores faltantes y formatos inconsistentes:

Algunas semanas presentaban registros nulos o con formato incorrecto (por ejemplo, comas decimales o separadores de miles).



→ *Solución*: se aplicaron transformaciones uniformes (to\_numeric con coerción) y técnicas de imputación (ffill y bfill) para asegurar continuidad temporal.

## 2. Alineación de series con diferentes longitudes:

Las series exógenas (COD2, COD24, COD25) no cubrían exactamente el mismo rango temporal que COD1.

→ *Solución*: se construyó un índice temporal común con frecuencia semanal (W-MON) y se reindexaron las series para lograr correspondencia exacta.

## 3. Heterogeneidad de escalas entre productos:

Los volúmenes de pedido variaban en órdenes de magnitud distintos entre códigos.

→ *Solución*: se aplicó una **estandarización z-score** antes de incorporarlas como exógenas, mejorando la estabilidad numérica del modelo SARIMAX.

## 4. Transformación logarítmica y estacionariedad:

La serie original mostraba cierta varianza no constante, por lo que se utilizó una **transformación  $\log(1 + y)$**  combinada con **diferenciación de primer orden ( $d=1$ )**, garantizando estacionariedad en media y varianza.

## 5. Selección de hiperparámetros:

Para SARIMA y SARIMAX, la búsqueda de parámetros óptimos se realizó combinando análisis de ACF/PACF con la automatización de auto\_arima, reduciendo tiempo y evitando sobreajuste.

## 6. Verificación de residuos:

En algunos modelos iniciales se detectaron residuos autocorrelacionados o heterocedásticos.

→ *Solución*: se realizaron iteraciones ajustando órdenes y aplicando pruebas Ljung-Box, ARCH LM y Jarque-Bera hasta obtener residuos con comportamiento de ruido blanco.

## 7. Comparación de modelos con distintos supuestos:

La coexistencia de modelos lineales (SARIMA) y suavizados (Holt-Winters) exigió un esquema de evaluación unificado.

→ *Solución*: se desarrolló una función común de evaluación con métricas (RMSE, MAE, MAPE,  $R^2$  y % error < 30%), lo que permitió una comparación objetiva entre todos los enfoques.

Estos pasos fueron clave para garantizar la robustez del análisis y la calidad de los resultados finales.

### 5.3. Relevancia para el negocio

El desarrollo de un sistema de pronóstico de demanda semanal como el realizado tiene **una importancia estratégica directa** para la gestión de la empresa analizada, tanto en el ámbito operativo como financiero:

- **Planificación de la producción:**

Un modelo confiable permite anticipar con precisión los volúmenes requeridos por semana, optimizando la utilización de la capacidad instalada, la programación de turnos y la compra de materias primas.

- **Gestión de inventarios y logística:**

Pronósticos precisos reducen la sobreproducción y el quiebre de stock, equilibrando el nivel de inventario y mejorando la eficiencia en la cadena de suministro.

- **Política comercial y financiera:**

Al conocer de antemano los períodos de mayor o menor demanda, se pueden planificar **campañas promocionales, gestión de precios y flujos de caja**, alineando decisiones tácticas y estratégicas.

- **Análisis de sustitución y complementariedad entre productos:**

La incorporación de variables exógenas (COD2, COD24, COD25) proporciona una visión más rica del **comportamiento conjunto de las familias de productos**, útil para la planificación del mix comercial y la segmentación de mercados.

En síntesis, disponer de pronósticos semanales robustos no solo mejora la eficiencia operativa, sino que **refuerza la capacidad de toma de decisiones basadas en datos (Data-Driven Management)**, contribuyendo a la sustentabilidad económica del negocio y a la reducción de la incertidumbre en la planificación.

### 5.4. Recomendaciones finales

A partir de los resultados y aprendizajes obtenidos, se proponen las siguientes recomendaciones para futuras etapas del proyecto:

1. **Ampliar la base de datos temporal:** incorporar más años de información histórica para capturar mejor los cambios estructurales del mercado y validar la estabilidad de los parámetros.
2. **Integrar nuevas variables explicativas:** como indicadores de eficiencia de despacho sobre pedido, festividades, precios relativos o campañas promocionales, que podrían aumentar la precisión predictiva del modelo SARIMAX.

3. **Implementar un sistema de actualización periódica:** automatizar la actualización de datos y el recalibrado de modelos para mantener la vigencia de las predicciones.
4. **Explorar modelos avanzados:** probar enfoques híbridos y de aprendizaje automático (XGBoost, LSTM, Prophet, etc.) que complementen los métodos clásicos con mayor capacidad de detección de patrones no lineales.
5. **Evaluar implementación en entorno de negocio:** integrar el modelo dentro de un panel de control o dashboard de planificación, permitiendo monitorear en tiempo real los desvíos entre demanda real y pronosticada.
6. **Extender el enfoque a otras familias de productos:** replicar la metodología para el resto del portafolio de elaborados, generando un modelo integral de demanda a nivel planta.